



Goldenizacja

Platforma integracji danych podstawowych podmiotów i osób





Plan

- 
- 
- Pobranie danych
 - Warstwa stagingu
 - Warstwa integracji
 - Warstwa analityczna
 - Prezentacja danych
 - Stack technologiczny

Pobranie danych



1 Pobranie danych

Proces rozpoczyna się od pozyskania danych z różnych źródeł (pliki, API, bazy danych, strumienie). → Prośba o doprecyzowanie danych, wskazania właściwych źródeł...

→ Rejestracja procesu

Każde pobranie danych jest rejestrowane w tabeli logów, aby śledzić:

- skąd pochodzą dane
- kiedy zostały pobrane
- na jakim etapie przetwarzania się znajdują (status)

→ Przechowywanie danych surowych

- dane zapisywane w repozytorium w oryginalnej formie
- przechowywane jako pliki lub rekordy (np. JSON/XML)
- brak transformacji na tym etapie
- pełne zachowanie danych źródłowych



→ Powiązanie danych

Każde pobranie danych jest powiązane z konkretnym zestawem danych surowych



Warstwa stagingu



Warstwa stagingu i walidacji

Dane surowe są przekształcane do ujednoliconego formatu oraz przygotowywane do dalszej integracji.

→ Transformacja danych

- parsowanie danych z różnych formatów (XML, JSON, CSV) do tabelarycznej struktury MS SQL
- rozdzielenie danych na dedykowane pola (np. rozbięcie pełnego adresu na ulicę, kod pocztowy, miasto)
- ujednolicenie typów danych (np. format daty, konwersja pól logicznych)

→ Walidacja danych

- sprawdzanie poprawności formatów (sumy kontrolne NIP, PESEL, REGON)
- weryfikacja braków w kluczowych atrybutach

→ Wzbogacenie danych

- wzbogacenie danych źródłowych na podstawie danych referencyjnych (np. uzupełnienie miasta na podstawie kodu pocztowego)

→ Powiązanie i audyt

Zachowanie pełnej relacji z danymi surowymi



Warstwa integracji



3 Warstwa integracji

Proces identyfikacji unikalnych podmiotów i osób poprzez łączenie rekordów z różnych źródeł oraz budowę „Golden Record”.

→ Standaryzacja i matching

- czyszczenie danych: usunięcie zbędnych znaków, ujednolicenie wielkości liter
- **zależności silne:** automatyczne łączenie po unikalnych identyfikatorach (PESEL, NIP)
- **zależności słabe:** dopasowanie na podstawie podobieństwa nazw i adresów przy użyciu algorytmów tekstowych

→ Grupowanie

- wyliczanie rankingu ufności dla każdego powiązania
- nadanie wspólnego klucza integracji dla wszystkich rekordów źródłowych dotyczących tej samej osoby lub firmy
- automatyczne łączenie pewnych rekordów i flaga do weryfikacji manualnej dla przypadków niejednoznacznych



3 Warstwa integracji

→ Mechanizm samouczący

- wykorzystanie modeli sztucznej inteligencji do automatyzacji procesów integracji i podniesienia precyzji dopasowań

→ Budowa "Golden Record"

- wybór najdokładniejszych danych na podstawie hierarchii zaufania do źródeł
- kompletowanie profilu: łączenie atrybutów z różnych systemów w jeden spójny profil 360 stopni
- zachowanie pełnej ścieżki pochodzenia danych (lineage) – wiemy, która część rekordu złotego pochodzi z jakiego pliku



Warstwa analityczna



Warstwa analityczna

Przekształcenie zintegrowanych danych w wielowymiarowe struktury gotowe do udostępniania.

→ Strukturyzacja Bazy Wiedzy

- organizowanie zgoldenizowanych rekordów w tabele faktów i wymiarów (model relacyjny)
- przekształcanie powiązań w struktury grafowe (struktury grafowe)



Prezentacja danych



5 Prezentacja danych

Wizualizacja profilu 360°, obsługa historyczności danych oraz szeroka dystrybucja wiedzy poprzez nowoczesne API REST.

→ Widok 360 stopni (Profil Podmiotu/Osoby)

- zagregowany widok wszystkich aktualnych danych (Złoty Rekord) w jednym miejscu
- możliwość "kliknięcia" w dowolny atrybut (np. adres), aby zobaczyć, z jakiego dokumentu/systemu pochodzi i jakie były jego alternatywne wersje

→ Interfejsy dostępne (REST API - Out)

- **Metoda GET:** interaktywne odpytywanie platformy przez systemy zewnętrzne w celu pobrania pełnego profilu lub widoków dedykowanych
- **Metoda PUSH:** automatyczne powiadamianie i przekazywanie danych do systemów w przypadku aktualizacji rekordów zgrupowanych

Stack technologiczny



Stack technologiczny

Backend:



Baza danych:



Integracja danych:




Środowisko uruchomieniowe:



Frontend:



Dziękujemy



Aleksandra Bamberska

Julia Nowakowska

Adam Biernacki

Sebastian Wróbel