

Platforma integracji danych podstawowych podmiotów i osób

Cel: Stworzenie autonomicznej platformy integracji danych podstawowych podmiotów i osób, umożliwiającej gromadzenie, przetwarzanie i udostępnianie danych w formie.

Zakres prac:

1. Analiza wymagań: Określenie wymagań funkcjonalnych i нефункциональных platformy.
2. Projekt architektury: Stworzenie architektury platformy, w tym warstwowości, modułów i mechanizmów.
3. Implementacja: Stworzenie platformy, w tym modułów odpowiedzialnych za:
 - a. Przyjmowanie i składowanie danych surowych
 - b. Walidację i ranking danych
 - c. Integrację danych
 - d. Udostępnianie danych
4. Testowanie: Przeprowadzenie testów platformy pod kątem funkcjonalności i wydajności.
5. Uruchomienie: Uruchomienie platformy i zapewnienie jej wsparcia.

Wymagania szczegółowe:

1. Stworzenie modułów odpowiedzialnych za poszczególne etapy integracji danych
2. Zapewnienie audytowalności danych
3. Wykorzystanie mechanizmów samouczących do integracji danych
4. Stworzenie interfejsu użytkownika umożliwiającego dostęp do danych

Kontekst funkcjonalny rozwiązania

Autonomiczna platforma integracji danych podstawowych (Master Data), to rozwiązanie informatyczne pełniące funkcję Centralnego Repozytorium Podmiotów i Osób, obejmujące swym zasięgiem wszystkie dane o podmiotach nadzorowanych i nienadzorowanych oraz osobach będących przedmiotem procesów nadzorczych we wszystkich pionach nadzoru i komórkach UKNF. Dane gromadzone, przetwarzane i składowane na platformie integracji danych podstawowych, stanowią Domenę Danych Współdzielonych Urzędu, zarządzaną przez CNT. Ze względu na różnorodny charakter danych źródłowych oraz specyfikę systemów i aplikacji wykorzystujących te dane, Platforma powinna zapewniać:

- standaryzowanie, integrowanie i goldenizację danych z wielu źródeł: pliki wsadowe, bazy relacyjne, strumienie danych, interfejsy REST, źródła referencyjne zewnętrzne i wewnętrzne;
- w pełni audytowalny proces przetwarzania, obejmujący znamionowanie (znakowanie) danych pierwotnych ze względu na: pierwotne pochodzenie, czas aktualizacji, wagę i istotność źródła, cel i sposób wykorzystania, ranking ufności na podstawie indeksów (miar jakości) danych;
- architekturę, uwzględniającą zmienność danych (stałe aktualne, wolno zmienne, chwilowo aktualne) oraz wymiarowy charakter danych (encje faktów, encje wymiarów). Rozważyć wykorzystanie technologii baz grafowych – węzły (nody), krawędzie (relacje), etykiety i właściwości – do odzwierciedlenia wielopoziomowych zależności i złożonych relacji, które pozwolą na wizualizację 360 stopni dla integrowanych encji;
- Zastosowanie mechanizmów samouczących, opartych o modele ML i DL, trenowane w sposób nadzorowany;

Elementy platformy integracji

Platforma integracji danych podstawowych zakłada utworzenie warstwy staging&validation, która zapewni gromadzenie danych surowych, składowanie w zunifikowanym repozytorium oraz kompleksowe walidacje danych, zapewniające dalszą transformację i integrację danych do postaci wielowymiarowej bazy wiedzy o podmiotach i osobach.

Przed przystąpieniem do projektowania platformy integracji danych podstawowych należy rozważyć następujące aspekty funkcjonalne:

1. koncepcja architektoniczna repozytorium:
 - a. jakie obiekty bazy,
 - b. co jest faktem, a co wymiarem,
 - c. jaki zakres informacyjny,
 - d. jakie klucze integracji
2. mechanizmy transformacji i składowania danych surowych
 - a. metody przekształcenia i standaryzacji danych na wejściu
 - b. niezbędne walidacje, wzbogacenia, znakowanie danych
 - c. składowanie w warstwie staging
3. integrowanie danych
 - a. jakie algorytmy goldenizacji, jakie klucze i priorytety
 - b. integracja wszystkich danych źródłowych z zachowaniem pierwotnego zakresu informacyjnego
 - c. mechanizm samouczący (algorytm ML/DL wytrenowany metoda nadzorowaną, zapewniający automatyczną identyfikację i integrację danych podmiotów/osób
4. udostępnianie danych
 - a. Widoki danych
 - b. Serwowanie przez interfejs REST
 - c. Audytowanie danych

Bloki funkcjonalne warstwy staging&validation

1. Moduł przyjęcia i składowania danych surowych – funkcjonalność skalowana ilością i rodzajem danych źródłowych
 - a. Przyjęcie i parsowanie plików separowanych (CSV), plików hierarchicznych w strukturze XML, XLS;
 - b. Przyjęcie i mapowanie instancji z relacyjnych baz danych (ODBC);
 - c. Przyjęcie i obsługa strumieni danych oraz interfejsów REST;
 - d. Dump danych ze źródeł referencyjnych wewnętrznych i zewnętrznych (KRS, GLEIF, słowniki PESEL, REGON/IDG, itp.);
2. Moduł walidacji i rankowania danych
 - a. Walidacja danych źródłowych algorytmami właściwymi dla danych źródłowych;
 - b. Indeksowanie danych źródłowych;
 - c. Znakowanie danych ze względu na pochodzenie, status (nowe dane/aktualizacja danych), czas aktualizacji, wagę i istotność źródła (hierarchia istotności źródeł, status aktywności w poszczególnych źródłach), cel i sposób wykorzystania;
 - d. Wyliczenie rankingu ufności na podstawie indeksów (miar jakości) danych;

3. Moduł wzbogacania

- a. Określenie zestawu danych wzbogacających dane źródłowe, na podstawie danych referencyjnych;
- b. Generowanie kluczy i znaczników integracji, według których nastąpi grupowanie i selekcjonowanie danych wchodzących w skład golden rekordu;

Bloki funkcjonalne warstwy transformacji, składowania i udostępniania

1. Moduł identyfikacji i integracji golden rekordów, zapewniający grupowanie rekordów zakwalifikowanych do integracji oraz wskazanie/utworzenie golden rekordu
2. Moduł generowania widoków i charakterystyk golden rekordów
 - a. Widoki podstawowe (pełne), zawierające wszystkie dane składowe golden rekordów oraz wszystkie warianty rekordów źródłowych, składających się na golden rekord, a także cechy po których dokonano goldenizacji;
 - b. Widoki dedykowane, zawierające wyselekcjonowane dane ze wszystkich wariantów rekordów źródłowych, dobrane pod względem specyficznych wymagań dla systemów, w których będą używane;
 - c. Słowniki referencyjne podmiotów i osób – zawierające unikalne dane o charakterze słownikowym, stanowiące wspólne źródło referencyjne dla systemów i aplikacji użytkowych.
3. Interfejs REST - Out
 - a. Metoda GET – interaktywne odpytywanie platformy integracji przez systemy i aplikacje
 - b. Metoda PUSH – przekazywanie danych do innych systemów i aplikacji w przypadku zmiany zawartości / aktualizacji rekordów zgrupowanych