

WARSTWA POBRANIA DANYCH

1. Model Składowania

Wszystkie dane, niezależnie od źródła, są traktowane jako nienaruszalne obiekty binarne i zapisywane w kolumnie **FILESTREAM**. Na tym etapie system nie parsuje danych

2. Metody pobierania według źródła

- **Pliki (CSV, XML, XLS, JSON):**
 - **Metoda:** Strumieniowe kopiowanie bajt po bajcie (`SqlFileStream`).
 - **Zasada:** Brak ingerencji w treść, zachowanie oryginalnego kodowania i błędów źródłowych.
- **Interfejsy API (REST/SOAP):**
 - **Metoda:** Serializacja odpowiedzi (Response Payload) do surowego pliku `.json` lub `.xml`.
 - **Zasada:** Całe body odpowiedzi z API ładuje w bazie jako jeden dokument binarny (lub paczka dokumentów przy paginacji).

3. Mechanizmy Kontrolne:

- **Rejestracja:** Każdy "plik" otrzymuje wpis w tabeli logów (źródło, kiedy, rozmiar, status).
- **Powiązanie:** Nadanie unikalnego `Load_ID`, który będzie towarzyszył danym na każdym kolejnym etapie obróbki (pełna audytowalność).

WARSTWA STAGINGU I WALIDACJI

1. Transformacja Danych

- **Metoda:** Wykorzystanie procedur składowanych T-SQL oraz funkcji natywnych (`OPENJSON`, `.nodes()`) do dekompozycji dokumentów binarnych na ustrukturyzowane rekordy tabelaryczne.
- **Sanityzacja (Cleaning):** Automatyczne usuwanie białych znaków (**Trimming**) oraz znaków niedrukowalnych na poziomie wczytywania do tabel stagingowych.

- **Algorytm Rozdzielania Pól (Splitting):** Implementacja reguł opartych na wyrażeniach regularnych (**Regex**) dla pól adresowych w celu separacji ulicy, numeru posesji i lokalu.
- **Unifikacja Typów:**
 - Konwersja dat do jednego formatu np. **YYYY-MM-DD**.
 - Mapowanie wartości logicznych np. na typ **BIT** (1 dla Prawdy, 0 dla Fałszu, NULL dla braku danych).

2. Walidacja Danych i Kontrola Jakości

- **Weryfikacja Algorytmiczna:** Implementacja rygorystycznych wag matematycznych dla polskich numerów identyfikacyjnych:
 - **REGON, PESEL, NIP:** Wykorzystanie profesjonalnej biblioteki **python-stdnum** do walidacji sum kontrolnych (np. modulo 11 dla NIP).
- **Walidacja Formatów:**
 - **E-mail:** Sprawdzenie składni oraz istnienia domeny (DNS MX check) przy użyciu biblioteki **email-validator**.
 - **Typowanie:** Weryfikacja poprawności typów (np. czy pola *Imię/Nazwisko* nie zawierają cyfr i są typu **String**).
- **Obsługa Błędów:** System nie przerywa procesowania przy błędnych danych. Rekordy, które nie przeszły walidacji, są znakowane flagą błędu wraz z konkretnym opisem (np. **ERR_CHECKSUM_NIP**), co umożliwia ich późniejszą analizę.

WARSTWA INTEGRACJI

1. Standaryzacja i Normalizacja (Preprocessing)

- **Zasada:** Doprowadzenie danych do wspólnego mianownika przed procesem porównywania, aby wyeliminować błędy wynikające z różnic w formatowaniu.
- **Czyszczenie danych:**
 - **Metoda:** Usunięcie zbędnych znaków specjalnych i normalizacja wielkości liter (UPPER CASE).

- **Biblioteki:** `text-unidecode` (do usuwania ogonków przy porównywaniu nazw) oraz `phonenumbers` (do standaryzacji telefonów do odpowiedniego formatu).
- **Geokodowanie:** Wykorzystanie biblioteki `geopy` do standaryzacji adresów (np. zamiana "ul. Marszałkowska" na ujednolicony format zgodny z mapami OpenStreetMap), co zwiększa skuteczność późniejszego matchingu.

2. Wielopoziomowy Matching

Proces identyfikacji tożsamości opiera się na analizie wielu atrybutów jednocześnie, z uwzględnieniem ich siły identyfikacyjnej i stabilności:

- **Zależności Silne:** Automatyczne łączenie na podstawie unikalnych i zweryfikowanych identyfikatorów (PESEL, NIP).
- **Zależności Słabe:** Wyliczanie prawdopodobieństwa tożsamości na podstawie wag atrybutów i ich dynamiki:
 - **Atrybuty Stałe (waga np. 0.9 - 1.0):** PESEL, NIP, Data urodzenia. Ich zgodność ma charakter rozstrzygający.
 - **Atrybuty Półstałe (waga np. 0.5 - 0.7):** Imię, Nazwisko. Porównywane algorytmem **Jaro-Winkler** (odporność na literówki).
 - **Atrybuty Dynamiczne (waga np. 0.2 - 0.4):** Telefon, E-mail, Adres. System dopuszcza ich zmianę w czasie i nie traktuje różnic jako błędu, jeśli dane stałe są zgodne.

3. Grupowanie i Ranking Ufności

- **Scoring Hybrydowy:** Wyliczanie zbiorczego wyniku podobieństwa. System stosuje algorytm **Levenshteina** dla tekstów i **Jaccarda** dla zestawów słów (np. nazwy firm).
- **Ranking Ufności Źródeł:** Przypisanie wag zaufania do systemów (np. Rejestr Państwowy = 1.0, Formularz WWW = 0.5). W przypadku konfliktu danych, system wybiera wartość z bardziej zaufanego źródła.
- **Zarządzanie Konfliktami:**
 - **Auto-merge:** Automatyczne łączenie dla wyników powyżej zdefiniowanego progu (np. >90%).
 - **Weryfikacja:** Flaga do manualnej oceny dla przypadków niejednoznacznych (np. 70-90% podobieństwa).

4. Mechanizm Samouczący (ML Optimization)

- **Algorytm:** Implementacja modelu **Random Forest**.
- **Zasada działania:** Model uczy się na podstawie historycznych decyzji "ręcznych" oraz interwencji operatorów.
- **Optymalizacja:** ML automatycznie dostosowuje wagi atrybutów (np. uczy się, że e-mail jest lepszym łącznikiem niż adres zamieszkania) i przejmuje procesowanie rekordów niejednoznacznych, redukując liczbę manualnych weryfikacji.

5. Budowa złotego rekordu

Na tym etapie system wykorzystuje zdefiniowane ogólnie reguły przetrwania danych, aby z wielu rekordów źródłowych złożyć jedną "najlepszą wersję prawdy".

- **Hierarchia Zaufania :** Każdy atrybut w Złotym Rekordzie jest wybierany na podstawie rankingu źródła.
- **Reguła "Latest Wins" (Aktualność):** Dla atrybutów o wysokiej dynamice zmian (telefon, adres) system stosuje kryterium daty załadowania (**Load_Date**). Najświeższy rekord nadpisuje starsze, zapewniając aktualność profilu 360 stopni.
- **Kompletowanie Atrybutów:** System scala dane. Jeśli Źródło A posiada NIP, a Źródło B posiada tylko e-mail, Złoty Rekord łączy oba te pola w jeden profil klienta.
- **Weryfikacja Manualna:** Rekordy, które uzyskały wynik podobieństwa w "szarej strefie" (np. 70-85%), trafiają do kwarantanny, gdzie człowiek ręcznie zatwierdza lub odrzuca połączenie.

Gdy system zgromadzi wystarczającą liczbę decyzji manualnych, model **Random Forest** przejmuje proces podejmowania decyzji o tym, jak powinien wyglądać Złoty Rekord.

- **Dynamiczne Wagi Atrybutów:** Model ML uczy się, że w pewnych grupach klientów (np. firmy) adres jest bardziej stabilny niż e-mail i automatycznie promuje go w procesie matchingu.
- **Klasyfikacja Konfliktów:** Zamiast prostego rankingu źródeł, ML analizuje kontekst. Jeśli dwa źródła o tym samym poziomie zaufania podają różne

dane, model sprawdza inne atrybuty (np. czy zmiana nazwiska koreluje ze zmianą stanu cywilnego lub adresu), aby podjąć autonomiczną decyzję.

- **Automatyczna Kwalifikacja:** Dzięki mechanizmowi samouczącemu, system z czasem eliminuje potrzebę manualnej weryfikacji dla większości przypadków, pozostawiając człowiekowi jedynie skrajne anomalie.

WARSTWA ANALITYCZNA

1. Wielowymiarowa Baza Wiedzy (Star Schema)

- **Cel:** Przekształcenie płaskiego „Złotego Rekordu” w strukturę umożliwiającą błyskawiczne raportowanie i budowę spójnej wiedzy o podmiotach.
- **Struktura Modelu:**
 - **Wymiary (Dimensions):** Wyodrębnienie encji opisujących stałe obiekty: **Osoba** (PESEL, data urodzenia), **Podmiot** (NIP, REGON), **Adres** (zgeokodowany przez GeoPy), **Źródło** (poziom zaufania) oraz **Czas**.
 - **Fakty (Facts):** Rejestracja zdarzeń takich jak: moment załadowania danych, każdorazowa aktualizacja atrybutu oraz wystąpienie relacji między podmiotami.
- **Mechanizm:** Powiązanie faktów z wymiarami za pomocą kluczy technicznych co pozwala na izolację danych analitycznych od zmian w systemach źródłowych.

2. Grafowa Reprezentacja Relacji (Relationship Intelligence)

- **Metoda:** Rozszerzenie klasycznego modelu relacyjnego o analizę powiązań sieciowych między osobami i podmiotami.
- **Mechanizmy:**
 - **Relacje Bezpośrednie:** Łączenie encji poprzez wspólne atrybuty (np. ten sam adres zamieszkania dla różnych osób lub ten sam NIP dla różnych ról biznesowych).
 - **Analiza Pośrednia (Graph Traversal):** Wykorzystanie struktur grafowych (**Neo4j**) do identyfikacji powiązań ukrytych.
- **Zasada:** Budowa pełnego widoku **360°** poprzez wizualizację powiązań kapitałowych i osobowych.

3. Analiza i Historia Danych

- **Metoda:** Implementacja mechanizmu, umożliwiającego analizę zmienności danych w czasie bez ich nadpisywania.
- **Mechanizmy:**
 - **Wersjonowanie:** Każda zmiana (np. zmiana nazwiska lub adresu) tworzy nową wersję rekordu z przypisanym okresem obowiązywania oraz ustawia odpowiedni status flagi `is_active`.
 - **Audytywanie:** Powiązanie każdej wersji z konkretnym `Load_ID` i źródłem danych, co pozwala prześledzić ewolucję wiedzy o podmiocie.
- **Zasada:** System pozwala na odtworzenie stanu wiedzy o kliencie z dowolnego punktu w przeszłości.

4. Fundament Widoku 360°

- **Agregacja:** Scalanie danych ze „Złotego Rekordu”, relacji grafowych oraz historii zmian w jeden, spójny interfejs informacyjny.
- **Zastosowanie:** Dostarczenie gotowych zbiorów danych.
- **Zasada:** Widok 360° nie jest tylko zdjęciem obecnego stanu, ale kompletną historią i mapą powiązań encji, zasilaną zweryfikowanymi danymi analitycznymi.

WARSTWA PREZENTACJI

1. Interfejs Złotego Rekordu

- **Cel:** Udostępnienie pełnego, skonsolidowanego profilu encji wraz z dowodami jego pochodzenia.
- **Mechanizmy:**
 - **Widok Kompletny:** Prezentacja danych "Złotego Rekordu"
 - **Widok Transparentny:** Wyświetlenie wszystkich rekordów źródłowych, które złożyły się na dany profil, co pozwala na porównanie różnic między systemami.
 - **Traceability:** Wizualizacja atrybutów, które posłużyły do matchingu (np. wskazanie, że rekordy połączono, bo miały ten sam NIP).
 - **Status i Cykl Życia:** Oznaczenie, czy dane są nowe, zaktualizowane czy archiwalne.

- **Zasada:** Użytkownik widzi nie tylko co jest w bazie, ale dlaczego system podjął taką decyzję o integracji.

2. Widoki Dedykowane i Agregaty

- **Cel:** Selekcja danych pod konkretne wymagania systemów trzecich.
- **Mechanizmy:**
 - **Filtracja:** Udostępnianie tylko niezbędnych atrybutów.
 - **Custom Mapping:** Dostosowanie nazw pól i formatów do specyficznych wymagań odbiorcy (np. zmiana formatu danych).
- **Zasada:** Minimalizacja przesyłanych danych oraz maksymalna użyteczność kontekstowa.

3. Komunikacja przez REST API (System-to-System)

- **Metoda:** Udostępnienie danych poprzez interfejs programistyczny.
- **Mechanizmy:**
 - **GET (Query):** Pobieranie pojedynczych rekordów lub list z wykorzystaniem filtrów (np. `GET /entities?city=Warszawa`).
 - **PUSH/Webhooks:** Automatyczne powiadamianie systemów zewnętrznych o zmianach (np. gdy w Golden Record zmieni się nazwisko, system wysyła paczkę z aktualizacją).
 - **Kontrola dostępu:** Autoryzacja zapytań zapewniająca bezpieczeństwo danych.
- **Zasada:** Dane są dostępne "na żądanie" w sposób bezpieczny i skalowalny.

4. Wyszukiwanie i Eksploracja

- **Cel:** Błyskawiczne odnajdywanie podmiotów w ogromnych zbiorach danych.
- **Mechanizmy:**
 - **Wyszukiwanie po Identyfikatorach:** Szybki dostęp przez unikalne klucze (PESEL, NIP, REGON).
 - **Filtrowanie Złożone:** Łączenie wielu kryteriów (np. "Wszystkie spółki z o.o. z Krakowa zarejestrowane w ostatnim miesiącu").
- **Zasada:** Intuicyjny i szybki dostęp do wiedzy zgromadzonej w systemie bez konieczności znajomości struktur bazodanowych.

